
Análisis Exploratorio de Datos (EDA)

Ciberseguridad Global

Tendencias, Impacto Financiero y Defensa (2015–2024)

Informe de Investigación – Proyecto Bootcamp

Autores: Stefany Builes Lopera
Jackeline Hernandez
Verónica Restrepo Betancur
Jaduer Zuñiga
Julio Javier Molinares Zapata
José David Ortiz Salazar
Camilo Piedrahita Alzate

Institución: [Talento Tech]
Dataset: Global Cybersecurity Threats 2015-2024
Fecha: 7 de abril de 2026

0 Índice

1. Introducción	3
1.1. Contexto y relevancia de la ciberseguridad global	3
1.2. Objetivos del análisis	4
1.3. Descripción del dataset	4
2. Metodología	5
3. Exploración Inicial del Dataset	8
3.1. Estadísticas descriptivas	8
4. Análisis Univariado	9
4.1. Histogramas generales de variables numéricas	9
4.2. Frecuencia de tipos de ataque	10
4.3. Registro de ataques por industria objetivo	11
4.4. Distribución de pérdidas financieras por rangos	12
4.5. Histogramas con estimación de densidad (KDE)	13
5. Análisis Bivariado	14
5.1. Distribución de tipos de ataque por industria	14
5.2. Distribución por fuente de ataque	15
5.3. Dispersión: Pérdida financiera por registro	16
5.4. Dispersión: Tiempo de resolución vs. pérdida financiera	17
6. Análisis Multivariado	17
6.1. Diagramas de caja (Boxplots)	18
6.2. Mapa de calor de correlación	19
6.3. Matriz de dispersión	20
7. Análisis Temporal	21
7.1. Tendencia de incidentes por año (2015–2024)	21
8. Discusión	22
9. Conclusiones	22
10. Referencias	24

Resumen

El presente informe documenta el Análisis Exploratorio de Datos (EDA) realizado sobre el dataset *Global Cybersecurity Threats 2015–2024*, que contiene 3.000 registros de incidentes cibernéticos a nivel mundial. El análisis abarca la distribución de tipos de ataque, sectores objetivo, fuentes de amenaza, impacto financiero y tiempos de resolución. Mediante técnicas estadísticas descriptivas y visualizaciones, se identificaron patrones clave que orientan la comprensión del panorama global de ciberseguridad. Los resultados sugieren que DDoS es el vector de ataque más frecuente, que el origen de las amenazas está distribuido entre grupos hacktivistas, actores estatales y amenazas internas, y que no existe correlación significativa entre el tiempo de resolución y el impacto financiero de los incidentes. Este trabajo constituye una base analítica para la toma de decisiones estratégicas en materia de defensa cibernética organizacional.

1 Introducción

1.1 Contexto y relevancia de la ciberseguridad global

En las últimas dos décadas, la transformación digital ha reconfigurado de manera profunda la estructura de las organizaciones, los gobiernos y la sociedad en su conjunto. La proliferación de dispositivos conectados, la migración masiva hacia entornos de cómputo en la nube, la expansión del Internet de las Cosas (IoT) y la adopción acelerada de tecnologías de inteligencia artificial han generado un ecosistema hiperconectado que, si bien potencia la productividad y la innovación, también amplía de forma exponencial la superficie de ataque disponible para actores maliciosos. En este contexto, la ciberseguridad ha emergido como una disciplina estratégica de primera línea, cuya relevancia trasciende el ámbito puramente técnico para posicionarse como un factor determinante de la continuidad operativa, la reputación corporativa y la seguridad nacional.

Los ciberataques representan hoy una de las amenazas más costosas y de mayor crecimiento a escala global. Según estimaciones de organismos internacionales como el Foro Económico Mundial y firmas especializadas como IBM y Cybersecurity Ventures, el costo global del cibercrimen superó los 8 billones de dólares en 2023, con proyecciones que apuntan a un incremento sostenido en los años venideros. Esta magnitud coloca a los incidentes cibernéticos entre los riesgos sistémicos más severos para la economía global, equiparables en impacto a fenómenos de orden geopolítico o climático. Las organizaciones que sufren brechas de seguridad no solo enfrentan pérdidas financieras directas —derivadas de pagos de rescate, costos de remediación y multas regulatorias— sino también daños intangibles de largo plazo, como la erosión de la confianza de clientes e inversores y la pérdida de ventaja competitiva por robo de propiedad intelectual.

La naturaleza de las amenazas cibernéticas ha evolucionado significativamente durante la última década. Los actores que operan en este espacio incluyen desde grupos de cibercrimen organizados motivados por el lucro económico, hasta actores patrocinados por estados-nación con objetivos geopolíticos de espionaje, sabotaje o influencia. A estos se suman los grupos hacktivistas, que emplean el ciberespacio como herramienta de protesta o presión política, y las amenazas internas, protagonizadas por empleados o colaboradores con acceso privilegiado a sistemas críticos. Esta diversidad de perfiles de amenaza exige que las organizaciones adopten estrategias de defensa multidimensionales, capaces de responder tanto a ataques externos sofisticados como a riesgos latentes en su propio interior.

Desde una perspectiva sectorial, ningún ámbito de la economía ha quedado exento del alcance de los ciberataques. No obstante, ciertos sectores concentran especial atención por parte de los actores maliciosos: las instituciones financieras, por el valor directo de los activos que custodian; el sector salud, cuya digitalización acelerada ha generado vastos repositorios de datos clínicos de alto valor; los gobiernos y agencias de defensa, por la sensibilidad de la información que gestionan; y el sector de tecnología de la información, que al ser el sustrato sobre el que operan todos los demás sectores, constituye un objetivo de alto impacto estratégico. La comprensión de los patrones de ataque, las vulnerabilidades más explotadas y los mecanismos

de defensa más efectivos en cada uno de estos sectores es, por tanto, una necesidad analítica de primer orden.

En este marco, el análisis de datos sobre incidentes cibernéticos constituye una herramienta fundamental para la inteligencia de amenazas y la formulación de políticas de seguridad basadas en evidencia. El Análisis Exploratorio de Datos (EDA) aplicado a conjuntos de datos de incidentes históricos permite identificar tendencias, correlaciones y patrones que no siempre resultan evidentes desde una perspectiva cualitativa, y que pueden orientar decisiones críticas en materia de asignación de recursos de seguridad, priorización de controles y diseño de planes de respuesta a incidentes.

1.2 Objetivos del análisis

- Describir la estructura y calidad del dataset de ciberseguridad global.
- Identificar los tipos de ataque más frecuentes y las industrias más afectadas.
- Analizar la distribución del impacto financiero y el número de usuarios afectados.
- Explorar las relaciones entre las variables numéricas mediante correlaciones.
- Visualizar patrones temporales en la ocurrencia de incidentes cibernéticos.

1.3 Descripción del dataset

El dataset utilizado contiene **3.000 registros** y **10 variables**, descritas en la Tabla 1.

Cuadro 1: Variables del dataset *Global Cybersecurity Threats 2015–2024*

Variable	Tipo	Descripción
Country	Categórica	País donde ocurrió el incidente
Year	Numérica	Año del incidente (2015–2024)
Attack Type	Categórica	Tipo de ciberataque (DDoS, Phishing, etc.)
Target Industry	Categórica	Sector industrial objetivo
Financial Loss (in Million \$)	Numérica	Pérdida económica estimada en millones de USD
Number of Affected Users	Numérica	Cantidad de usuarios comprometidos
Attack Source	Categórica	Origen de la amenaza
Security Vulnerability Type	Categórica	Tipo de vulnerabilidad explotada
Defense Mechanism Used	Categórica	Mecanismo de defensa empleado
Incident Resolution Time (in Hours)	Numérica	Tiempo de resolución del incidente en horas

2 Revisión de Literatura

Los reportes anuales de referencia en la industria documentan de manera sistemática la evolución del panorama de amenazas cibernéticas. El *Data Breach Investigations Report* de Verizon Communications (2024) analiza miles de incidentes confirmados a nivel mundial y establece que los vectores de ataque más prevalentes incluyen el phishing, el ransomware y los ataques de denegación de servicio distribuido (DDoS), con una tendencia creciente en la sofisticación de los actores y en la diversificación de los sectores objetivo. En la misma línea, el informe de IBM Security (2024) cuantifica el costo promedio de una brecha de datos en cifras que superan los cuatro millones de dólares, destacando que el tiempo de contención del incidente es uno de los factores con mayor influencia sobre el impacto financiero final. Estos hallazgos contextualizan los resultados del presente EDA, en particular la distribución uniforme de pérdidas financieras y la ausencia de correlación entre tiempo de resolución e impacto económico observadas en el dataset analizado.

Desde una perspectiva institucional, el *Global Cybersecurity Outlook* del **wef2024**<empty citation> identifica la ciberseguridad como uno de los riesgos sistémicos más severos para la

economía global, equiparable en magnitud a fenómenos geopolíticos o climáticos. El informe subraya que la brecha entre organizaciones ciberresistentes y aquellas con capacidades limitadas de defensa continúa ampliándose, lo que refuerza la necesidad de herramientas analíticas accesibles —como el EDA aplicado a datasets históricos— para democratizar el conocimiento sobre patrones de ataque y orientar inversiones en seguridad independientemente del tamaño organizacional.

La literatura especializada es consistente en señalar que diferentes vectores de ataque presentan afinidades sectoriales bien documentadas. European Union Agency for Cybersecurity (ENISA) (2023) reporta que el ransomware afecta de manera desproporcionada al sector salud, donde la urgencia operativa genera incentivos para el pago de rescates, y al sector educativo, históricamente limitado en presupuestos de seguridad. Los ataques de inyección SQL, por su parte, se concentran en organizaciones del sector financiero y del comercio minorista, donde las bases de datos de clientes con información de tarjetas de pago constituyen objetivos de alto valor. Esta especificidad sectorial, ausente en el dataset sintético analizado en el presente trabajo debido a su diseño balanceado, representa una de las principales limitaciones a considerar al extrapolar los hallazgos a contextos operativos reales (Verizon Communications, 2024).

La diversidad de actores en el ecosistema de amenazas cibernéticas es otro elemento central en la literatura reciente. European Union Agency for Cybersecurity (ENISA) (2023) clasifica los actores en cuatro grandes categorías: grupos de cibercrimen organizado motivados por el lucro económico, actores patrocinados por estados-nación con objetivos geopolíticos, grupos hacktivistas que emplean el ciberespacio como herramienta de presión política, y amenazas internas protagonizadas por empleados o colaboradores con acceso privilegiado. La cuasi-paridad entre estas categorías observada en el dataset analizado —con actores estatales representando el 26.5 %, fuentes desconocidas el 25.6 %, amenazas internas el 25.1 % y grupos hacktivistas el 22.9 %— guarda coherencia con la distribución reportada por Verizon Communications (2024), que también destaca el peso creciente de las amenazas internas como vector de riesgo subestimado en las estrategias de defensa organizacional.

El análisis de incidentes cibernéticos no puede desvincularse del marco regulatorio y normativo en el que operan las organizaciones. El *Cybersecurity Framework* del National Institute of Standards and Technology (2018) proporciona una estructura de cinco funciones —Identificar, Proteger, Detectar, Responder y Recuperar— que orienta la gestión del riesgo cibernético de manera integral y que sirve como referencia para interpretar los hallazgos del presente EDA. En particular, la ausencia de correlación entre el tiempo de resolución y el impacto financiero identificada en el análisis es coherente con el énfasis del marco NIST en las funciones de Identificar y Proteger —es decir, los controles preventivos— como determinantes primarios de la resiliencia organizacional, por encima de la eficiencia reactiva en la fase de Responder. Este hallazgo tiene implicaciones presupuestarias directas para las organizaciones que buscan optimizar su retorno sobre la inversión en ciberseguridad.

El ecosistema de herramientas de código abierto para el análisis de datos ha facilitado la democratización del EDA aplicado a la ciberseguridad. La biblioteca **pandas** (McKinney, 2010) provee las estructuras de datos y operaciones de manipulación necesarias para procesar grandes volúmenes de registros de incidentes; **NumPy** (harris2020) sustenta las operaciones numéricas de alta eficiencia; **Matplotlib** (hunter2007) y **Seaborn** (Waskom, 2021) permiten construir visualizaciones estadísticas que facilitan la identificación de patrones distribucionales; y **Plotly Express** (plotly2015) añade capacidades de visualización interactiva especialmente útiles para el análisis bivariado por categorías. La estimación de densidad de kernel aplicada en el análisis univariado sigue los fundamentos teóricos establecidos por Silverman (1986), cuya regla de selección del ancho de banda óptimo continúa siendo el estándar de referencia en la literatura estadística. Finalmente, **scikit-learn** (pedregosa2011) constituye la biblioteca de referencia para la aplicación futura de modelos de aprendizaje automático sobre el dataset, representando el paso natural que extiende los hallazgos del EDA hacia la construcción de herramientas predictivas de soporte a la decisión en materia de gestión del riesgo cibernético.

3 Metodología

El análisis se desarrolló utilizando el lenguaje de programación Python (versión 3.12) en el entorno Google Colaboratory, apoyado en las siguientes bibliotecas: **Pandas** para carga y manipulación del dataset; **NumPy** para operaciones numéricas; **Matplotlib** y **Seaborn** para visualizaciones estáticas; **Plotly Express** para visualizaciones interactivas; y **ydata-profiling** para la generación automatizada del reporte de perfilado.

El proceso siguió las etapas clásicas del EDA: (1) carga e inspección inicial, (2) verificación de calidad de datos, (3) análisis univariado, (4) análisis bivariado y multivariado, y (5) interpretación de resultados.

El proceso siguió cinco etapas secuenciales:

1. **Carga e inspección inicial:** verificación de dimensiones, tipos de datos, valores nulos y estadísticas de resumen.
2. **Análisis univariado:** caracterización individual de cada variable.
3. **Análisis bivariado:** exploración de relaciones entre pares de variables.
4. **Análisis multivariado:** evaluación conjunta mediante correlaciones, diagramas de caja y matrices de dispersión.
5. **Análisis temporal:** estudio de la distribución de incidentes a lo largo del período 2015–2024.

Para cada variable numérica se calcularon las medidas de tendencia central y dispersión estándar. La **media aritmética** se define como:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

donde x_i es el valor del i -ésimo registro y n el número total de observaciones. La **desviación estándar muestral** cuantifica la dispersión de los datos alrededor de la media:

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (2)$$

Adicionalmente, se calcularon los **cuartiles** Q_1 (percentil 25), Q_2 (mediana, percentil 50) y Q_3 (percentil 75), así como el **rango intercuartílico** (IQR):

$$\text{IQR} = Q_3 - Q_1 \quad (3)$$

El IQR constituye una medida robusta de dispersión, menos sensible a valores extremos que la desviación estándar, y es la base de los diagramas de caja (*boxplots*) (Tukey, 1977).

Las distribuciones de las variables numéricas se visualizaron mediante **histogramas** con 30 intervalos (*bins*). Para complementar la interpretación, se superpuso una curva de **estimación de densidad de kernel** (KDE), que proporciona una aproximación no paramétrica de la función de densidad de probabilidad. La estimación KDE en un punto x se define como:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right) \quad (4)$$

donde $K(\cdot)$ es la función kernel (en este caso, una función gaussiana estándar) y h es el ancho de banda (*bandwidth*), que controla el nivel de suavizado:

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} \quad (5)$$

El ancho de banda óptimo se determinó mediante la regla de Silverman:

$$h^* = 1,06 \hat{\sigma} n^{-1/5} \quad (6)$$

donde $\hat{\sigma}$ es la desviación estándar muestral de los datos (Silverman, 1986).

Las variables categóricas (tipo de ataque, industria objetivo, fuente de ataque) se analizaron mediante tablas de frecuencias absolutas y relativas. Para una categoría c_j con f_j observaciones en una muestra de tamaño n , la **frecuencia relativa** es:

$$p_j = \frac{f_j}{n}, \quad \sum_{j=1}^k p_j = 1 \quad (7)$$

donde k es el número total de categorías. Los resultados se representaron gráficamente mediante diagramas de barras verticales, horizontales y gráficos de pastel (*pie charts*).

El análisis de relaciones entre las variables numéricas se basó en el **coeficiente de correlación lineal de Pearson** (r), que mide el grado de asociación lineal entre dos variables X e Y :

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (8)$$

El coeficiente toma valores en el intervalo $[-1, 1]$: valores próximos a ± 1 indican una asociación lineal fuerte (positiva o negativa), mientras que valores próximos a 0 evidencian independencia lineal entre las variables. Los resultados se visualizaron en una **matriz de calor** (*heatmap*) empleando la paleta de colores *coolwarm* (Waskom, 2021).

Los *boxplots* o diagramas de caja resumen gráficamente cinco estadísticos clave de cada variable: mínimo, Q_1 , mediana (Q_2), Q_3 y máximo. Los **valores atípicos** (*outliers*) se identifican mediante la regla de las vallas de Tukey:

$$\text{Valla inferior} = Q_1 - 1,5 \cdot \text{IQR}, \quad \text{Valla superior} = Q_3 + 1,5 \cdot \text{IQR} \quad (9)$$

Todo valor que supere dichas vallas es considerado un potencial valor atípico y se representa como un punto individual fuera de los bigotes del diagrama (Tukey, 1977).

Para el análisis multivariado visual se construyó una **matriz de dispersión** mediante la función `pd.plotting.scatter_matrix` de `pandas` (McKinney, 2010). Esta representación matricial $p \times p$ muestra en cada celda fuera de la diagonal el gráfico de dispersión entre el par de variables correspondiente, mientras que la diagonal presenta la distribución marginal de cada variable. Su principal utilidad es detectar relaciones no lineales o estructuras de agrupamiento latentes que el coeficiente de Pearson no captura.

El dataset exhibe distribuciones uniformes en sus variables numéricas, característica indicativa de un origen **sintético o balanceado** artificialmente. Esta particularidad tiene implicaciones metodológicas importantes: (a) facilita el aprendizaje estadístico porque ningún rango de valores está sobrerrepresentado, reduciendo el sesgo de entrenamiento; pero (b) limita la extrapolación de los resultados a contextos reales, donde las distribuciones suelen ser asimétricas positivas con colas pesadas en el impacto financiero, tal como documentan el *Data Breach Investigations Report* (Verizon Communications, 2024) y el *Cost of a Data Breach Report* (IBM Security, 2024). Esta divergencia debe ser explícitamente reconocida al generalizar los hallazgos a entornos operativos reales.

Asimismo, los marcos normativos de referencia en materia de gestión de riesgos cibernéticos —como el *Cybersecurity Framework* del NIST (National Institute of Standards and Technology, 2018) y el panorama de amenazas de la ENISA (European Union Agency for Cybersecurity (ENISA), 2023)— orientan la interpretación práctica de los patrones identificados en el análisis.

4 Exploración Inicial del Dataset

4.1 Estadísticas descriptivas

Tras la carga del dataset, se verificó que contiene exactamente 3.000 filas y 10 columnas, sin valores nulos en ninguna variable. La Tabla 2 resume las estadísticas descriptivas de las variables numéricas.

Cuadro 2: Estadísticas descriptivas de las variables numéricas

Variable	Media	Desv. Est.	Mín.	Q25	Q50	Máx.
Year	2019.57	2.86	2015	2017	2020	2024
Financial Loss (M\$)	50.49	28.79	0.50	25.76	50.80	~100
Number of Affected Users	504,684	289,944	424	255,805	504,513	~10 ⁶
Resolution Time (h)	36.48	20.57	1	19	37	72

Las estadísticas descriptivas revelan que el dataset se encuentra en un estado óptimo para el análisis, sin valores ausentes ni registros duplicados detectados. La variable *Financial Loss* presenta una media de \$50.49M y una desviación estándar de \$28.79M, lo que indica una dispersión considerable alrededor del valor central, coherente con la diversidad de tipos de ataque y sectores objetivo representados en el dataset. El tiempo de resolución promedio de 36.48 horas evidencia que la mayoría de los incidentes se resuelven en un plazo inferior a dos días, aunque la variabilidad de 20.57 horas sugiere que ciertos incidentes de mayor complejidad pueden extenderse significativamente.

5 Análisis Univariado

A continuación se presentan los resultados del análisis univariado de las variables clave del proyecto, haciendo especial énfasis en analizar la estructura distribucional de estas variables.

5.1 Histogramas generales de variables numéricas




Figura 1: Histogramas generales del DataFrame completo (`data.hist`). Se muestran las distribuciones de *Year*, *Financial Loss*, *Number of Affected Users* e *Incident Resolution Time*, con 30 bins y bordes negros para facilitar la lectura.

Los histogramas generales revelan que la distribución temporal de los incidentes es relativamente uniforme a lo largo de los años 2015–2024, con aproximadamente 300 incidentes por año. La pérdida financiera y el número de usuarios afectados presentan distribuciones uniformes en sus rangos, sin concentraciones en valores extremos. El tiempo de resolución también se distribuye de manera cuasi-uniforme entre 1 y 72 horas.

Desde una perspectiva estadística, la forma rectangular de los histogramas es indicativa de una distribución uniforme continua, lo que implica que cada intervalo de valores tiene aproximadamente la misma probabilidad de ocurrencia. Esta característica, si bien reduce la capacidad de detectar patrones de concentración de riesgo, resulta metodológicamente conveniente para el entrenamiento de modelos de aprendizaje automático, ya que garantiza que ninguna clase o rango de valores esté sobrerrepresentado, mitigando así el sesgo de entrenamiento. En un contexto aplicado, esta uniformidad podría interpretarse como evidencia de que los ataques cibernéticos no discriminan por nivel de impacto: incidentes de bajo, mediano y alto costo ocurren con frecuencias comparables, lo que refuerza la necesidad de que las organizaciones mantengan una postura de defensa activa independientemente del tamaño o perfil de riesgo percibido.

5.2 Frecuencia de tipos de ataque




Figura 2: Gráfico de barras verticales con la frecuencia de cada tipo de ciberataque registrado en el dataset. El eje X muestra los distintos vectores de ataque y el eje Y indica el número de incidentes observados para cada categoría.

Los seis tipos de ataque registrados (DDoS, Phishing, Ransomware, Man-in-the-Middle, SQL Injection y Malware) presentan frecuencias relativamente similares. DDoS es el más frecuente según el análisis descriptivo del subconjunto D (*top = DDoS, freq = 183*). Esta uniformidad puede indicar que el dataset fue construido de manera balanceada, aunque el dominio de DDoS refleja su prevalencia real como el vector de ataque más utilizado por volumen a nivel global.

La paridad entre los seis vectores de ataque tiene implicaciones estratégicas relevantes: ningún tipo de amenaza puede ser tratado como marginal o secundario en la planificación de la seguridad organizacional. Los ataques de tipo Phishing y Ransomware, que en el entorno real han mostrado un crecimiento exponencial en los últimos años —especialmente tras la pandemia de COVID-19 y la adopción masiva del trabajo remoto—, aparecen representados con una frecuencia equiparable a los ataques DDoS, lo que subraya la necesidad de contar con defensas especializadas para cada vector. Los ataques Man-in-the-Middle y SQL Injection, aunque técnicamente más complejos de ejecutar, continúan siendo amenazas vigentes, particularmente en

entornos con infraestructuras tecnológicas desactualizadas o mal configuradas. Esta distribución equilibrada debe orientar las inversiones en capacitación, monitoreo y herramientas de detección hacia un enfoque holístico que no privilegie un único tipo de amenaza.

5.3 Registro de ataques por industria objetivo




Figura 3: Distribución de incidentes cibernéticos por industria objetivo, representada mediante un gráfico de barras horizontales. El eje Y muestra los sectores económicos y el eje X indica la frecuencia de ataques recibidos por cada uno.

Los sectores más atacados corresponden a industrias de alto valor estratégico: tecnología de la información, servicios financieros, salud y gobierno. La distribución es relativamente pareja entre sectores, lo que evidencia una superficie de ataque amplia. En el contexto real, IT, finanzas y gobierno son objetivos prioritarios por el valor de los datos que custodian y la criticidad de sus operaciones.

La distribución intersectorial observada plantea un escenario de amenaza omnipresente en el que ningún sector puede considerarse exento del riesgo cibernético. El hecho de que sectores como telecomunicaciones, educación y comercio minorista aparezcan con frecuencias de ataque comparables a las de banca y gobierno desafía la percepción tradicional que asociaba el ciberriesgo exclusivamente con entidades de alto perfil financiero o gubernamental. Esta democratización del riesgo cibernético obedece en parte a la creciente interconexión entre sectores —a través de cadenas de suministro digital, APIs compartidas y proveedores de servicios en la nube— que convierte a cualquier organización en un potencial vector de ataque hacia objetivos de mayor valor. Las industrias de educación y telecomunicaciones, en particular, han emergido como objetivos atractivos por la cantidad masiva de datos personales que gestionan y por la criticidad de sus redes para el funcionamiento de otros sectores.

5.4 Distribución de pérdidas financieras por rangos




Figura 4: Distribución de incidentes según rangos de pérdida financiera en intervalos de 10 millones de USD (de \$0M a \$100M). Permite identificar qué nivel de impacto económico ocurre con mayor frecuencia en el dataset.

La distribución de incidentes según el rango de pérdida financiera es uniforme a lo largo de todos los intervalos de 10M USD, con aproximadamente el mismo número de incidentes en cada rango. Aunque esto refleja la naturaleza sintética del dataset, resulta útil para modelar escenarios de planificación de presupuestos de seguridad donde los impactos pueden ser de cualquier magnitud.

La ausencia de una concentración marcada en los rangos de menor impacto —comportamiento que sería esperable en un dataset real, donde la mayoría de los incidentes corresponden a eventos de bajo costo— confirma el origen sintético y balanceado de los datos. No obstante, esta característica ofrece una ventaja analítica desde el punto de vista del modelado: al trabajar con una distribución uniforme, los modelos predictivos desarrollados a partir de este dataset no tenderán a subestimar la probabilidad de incidentes de alto impacto, un sesgo común en los modelos entrenados con datos reales donde los eventos catastróficos son estadísticamente raros. Para la planificación práctica de la seguridad, este comportamiento uniforme puede interpretarse como una señal de que toda organización debe estar preparada para absorber pérdidas en cualquier punto del espectro financiero, y no solo para eventos de magnitud moderada.

5.5 Histogramas con estimación de densidad (KDE)




Figura 5: Distribución de las cuatro variables numéricas clave con curva de estimación de densidad de kernel (KDE) superpuesta: *Financial Loss*, *Number of Affected Users*, *Incident Resolution Time* y *Year*. La curva KDE facilita la interpretación de la forma de cada distribución.

Las cuatro variables numéricas presentan un comportamiento cuasi-uniforme, lo que confirma el balance del dataset. La variable *Financial Loss* muestra una distribución plana entre 0 y 100M USD con la curva KDE prácticamente horizontal. De manera similar, el número de usuarios afectados y el tiempo de resolución carecen de una moda pronunciada, lo que indica que el dataset no favorece ningún rango de valores en particular.

La superposición de la curva KDE sobre los histogramas permite identificar con mayor precisión las leves asimetrías que el ojo humano no detecta fácilmente en barras discretas. La curva KDE de la variable *Year* muestra una ligera depresión en los años centrales del período analizado (2018–2019), mientras que los extremos temporales (2015 y 2024) presentan una densidad algo menor, probablemente como artefacto del método de suavizado de kernel en los bordes de la distribución. En el caso de *Number of Affected Users*, la curva KDE evidencia una leve caída en los valores cercanos al máximo ($\sim 10^6$), lo que podría interpretarse como una limitación del dataset en la representación de mega-incidentes —aquellos que afectan a millones de usuarios simultáneamente—, que son estadísticamente raros en el mundo real pero de alto impacto mediático y regulatorio.

6 Análisis Bivariado

6.1 Distribución de tipos de ataque por industria




Figura 6: Gráfico de barras agrupadas interactivo (Plotly Express) que muestra la cantidad de incidentes por industria objetivo, segmentado por tipo de ataque. Cada color representa un vector de ataque distinto, permitiendo comparar la distribución de amenazas entre sectores.

El gráfico de barras agrupado permite observar que todos los tipos de ataque se distribuyen de manera similar en las distintas industrias objetivo, sin una concentración de un vector específico en un sector particular. En la práctica, sectores como salud y gobierno son más vulnerables a ransomware, mientras que las organizaciones financieras enfrentan mayor proporción de phishing y fraude. La uniformidad observada aquí es característica del diseño sintético del dataset.

La ausencia de especificidad sectorial en la distribución de vectores de ataque, aunque esperada en un dataset sintético, contrasta con la evidencia empírica disponible

en la literatura especializada. Estudios sectoriales recientes documentan que el ransomware tiene una incidencia desproporcionadamente alta en el sector salud —donde la urgencia operativa crea incentivos para el pago de rescates— y en el sector educativo —cuyos presupuestos de seguridad son históricamente limitados—. Del mismo modo, los ataques de SQL Injection afectan de manera predominante a organizaciones del sector retail y financiero, donde las bases de datos de clientes con información de tarjetas de pago constituyen un objetivo de alto valor. Este contraste entre los datos del dataset y la realidad documentada debe tenerse en cuenta al momento de generalizar los hallazgos de este EDA a contextos operativos reales, y refuerza la importancia de complementar el análisis cuantitativo con inteligencia de amenazas específica para cada sector.

6.2 Distribución por fuente de ataque




Figura 7: Gráfico de pastel que muestra la distribución porcentual de incidentes según la fuente de ataque. Las cuatro categorías son: actores de estado-nación (*Nation-state*, 26.5 %), fuentes desconocidas (*Unknown*, 25.6 %), amenazas internas (*Insider*, 25.1 %) y grupos de hackers (*Hacker Group*, 22.9 %).

El gráfico de pastel revela que las fuentes de ataque están distribuidas de manera cuasi-uniforme entre las cuatro categorías. La proporción significativa de amenazas internas (25.1 %) es especialmente relevante, ya que subraya que el riesgo no proviene únicamente de actores externos, sino también de personas con acceso privilegiado. La alta proporción de fuentes desconocidas (25.6 %) refleja la dificultad de atribución en el ámbito de la ciberseguridad.

La cuasi-paridad entre actores estatales (26.5 %), fuentes desconocidas (25.6 %), amenazas internas (25.1 %) y grupos hacktivistas (22.9 %) tiene implicaciones de alto calado para la arquitectura de seguridad organizacional. La significativa presencia de amenazas internas impone la necesidad de implementar modelos de confianza cero (*zero trust architecture*), en los cuales ningún usuario o sistema, independientemente de su posición dentro o fuera de la red corporativa, recibe acceso implícito a recursos críticos sin autenticación continua y verificación explícita de privilegios mínimos. La proporción de fuentes desconocidas, por su parte, subraya las limitaciones de los mecanismos actuales de atribución cibernética y la necesidad de invertir en capacidades de inteligencia de amenazas y análisis forense digital que permitan reducir el porcentaje de incidentes sin atribución identificada, elemento clave para el diseño de respuestas estratégicas tanto a nivel organizacional como a nivel de política pública.

6.3 Dispersión: Pérdida financiera por registro




Figura 8: Gráfico de dispersión de la pérdida financiera (en millones de USD) para los 3.000 registros del dataset. La línea roja discontinua representa la media (\$50.49M), permitiendo visualizar la distribución de valores alrededor del punto central.

El gráfico de dispersión confirma que los valores de pérdida financiera se distribuyen de manera uniforme entre 0 y 100M USD a lo largo de todos los registros, sin tendencias temporales ni agrupamientos. La media de \$50.49M actúa como punto de equilibrio con aproximadamente la misma cantidad de registros por encima y por debajo, lo que implica que no existe sesgo hacia incidentes de alto o bajo impacto financiero.

La dispersión homogénea de los valores a lo largo del índice de registros descarta la existencia de cualquier estructura temporal subyacente en la variable de impacto financiero: los incidentes de alto costo no tienden a concentrarse en períodos específicos del dataset, lo que indica que el proceso de generación de datos es estacionario en términos de impacto económico. Desde una perspectiva de gestión del riesgo, este comportamiento estacionario implica que la planificación de reservas financieras para la atención de incidentes cibernéticos no puede basarse en ciclos temporales predecibles, sino que debe contemplar una exposición constante a pérdidas de cualquier magnitud. Este hallazgo refuerza la importancia de contar con seguros de ciberriesgo y fondos de contingencia permanentemente activos, en lugar de estrategias de provisión estacional.

6.4 Dispersión: Tiempo de resolución vs. pérdida financiera




Figura 9: Relación entre el tiempo de resolución del incidente (eje X, en horas) y la pérdida financiera asociada (eje Y, en millones de USD). Permite explorar visualmente si los incidentes que tardan más en resolverse generan mayores pérdidas económicas.

El gráfico de dispersión no revela correlación entre el tiempo de resolución y la pérdida financiera: los puntos se distribuyen de forma dispersa y sin una tendencia lineal observable. Esto sugiere que la velocidad de respuesta por sí sola no determina la magnitud del daño económico, y que factores como el tipo de ataque, el sector objetivo y los recursos de respuesta tienen mayor influencia.

La ausencia de correlación entre estas dos variables desafía la intuición convencional que asume que una respuesta más rápida se traduce necesariamente en menores pérdidas económicas. Este resultado sugiere que el daño financiero de un ciberataque está determinado en mayor medida por factores previos al incidente —como la robustez de los controles preventivos, la arquitectura de segmentación de redes, la sensibilidad de los datos comprometidos y el nivel de cobertura de seguros— que por la eficiencia del equipo de respuesta una vez que el ataque ya ha sido ejecutado. Esta distinción tiene implicaciones presupuestarias directas: las organizaciones obtienen un mayor retorno sobre su inversión en seguridad al destinar recursos a controles preventivos y arquitecturas de resiliencia que al dimensionamiento exclusivo de equipos de respuesta a incidentes, si bien ambos componentes son necesarios dentro de una estrategia integral de ciberseguridad.

7 Análisis Multivariado

7.1 Diagramas de caja (Boxplots)




Figura 10: Diagramas de caja (*boxplots*) para las tres métricas numéricas principales: pérdida financiera (*Financial Loss*), número de usuarios afectados (*Number of Affected Users*) y tiempo de resolución (*Incident Resolution Time*). Se muestran los valores atípicos como puntos individuales.

Los boxplots muestran que las tres variables presentan una distribución simétrica con mediana central bien definida. Para *Financial Loss*, la mediana se sitúa alrededor de \$50M con el rango intercuartílico (IQR) entre \$25M y \$75M. El número de usuarios afectados tiene una mediana próxima a 500.000. El tiempo de resolución presenta una mediana en torno a 37 horas con IQR entre 19 y 55 horas. La ausencia de valores atípicos extremos confirma la uniformidad del dataset.

La simetría de los tres boxplots, evidenciada por la posición central de la mediana dentro de la caja y la longitud equivalente de los bigotes superior e inferior, confirma que ninguna de las variables presenta asimetría o sesgo estadísticamente relevante. En un contexto de análisis de riesgo, la ausencia de valores atípicos extremos merece especial atención: los incidentes más costosos o de mayor duración no se distancian significativamente de los valores centrales, lo que indica que el dataset no captura adecuadamente los escenarios catastróficos —aquellos que en el mundo real generan las mayores pérdidas y que típicamente se representan como valores atípicos severos en distribuciones asimétricas positivas. Para una aplicación práctica del modelo, sería

recomendable enriquecer el dataset con registros de mega-incidentes documentados en fuentes abiertas, como los ataques a Colonial Pipeline, SolarWinds o el sistema de salud irlandés HSE, que representan el extremo superior del espectro de impacto y cuya inclusión dotaría al análisis de mayor poder predictivo para escenarios de alto riesgo.

7.2 Mapa de calor de correlación




Figura 11: Matriz de correlación de las variables numéricas del dataset visualizada como mapa de calor. Los valores anotados son los coeficientes de correlación de Pearson entre cada par de variables. La escala de color *coolwarm* diferencia correlaciones positivas (rojo) de negativas (azul).

El mapa de calor es uno de los hallazgos más relevantes del análisis: evidencia correlaciones prácticamente nulas entre *Financial Loss*, *Number of Affected Users* e *Incident Resolution Time*. Los coeficientes de Pearson se aproximan a 0.00, con el valor más extremo siendo -0.01 . Esto implica que las métricas son estadísticamente independientes, por lo que no es posible predecir el impacto financiero ni el tiempo de resolución directamente a partir de las otras variables numéricas disponibles.

La independencia estadística entre las tres variables numéricas centrales es, desde el punto de vista del modelado predictivo, una limitación fundamental del dataset en su estado actual. Un coeficiente de correlación de Pearson próximo a cero entre pérdida financiera y número de usuarios afectados implica que comprometer a un mayor número de personas no se traduce necesariamente en una mayor pérdida económica —lo que sí ocurre en la realidad, donde las brechas masivas de datos generan

costos regulatorios (multas del GDPR, notificaciones obligatorias) proporcionales al volumen de afectados. Esta discrepancia entre los datos sintéticos y la realidad documentada sugiere que cualquier modelo de clasificación o regresión entrenado sobre este dataset deberá ser validado cuidadosamente antes de su aplicación en entornos reales, preferiblemente mediante técnicas de validación cruzada sobre datos reales complementarios o mediante la incorporación de variables categóricas como el tipo de ataque o el sector objetivo como predictores adicionales.

7.3 Matriz de dispersión




Figura 12: Matriz de dispersión (*scatter matrix*) generada con `pd.plotting.scatter_matrix` sobre el subconjunto D (998 registros). Las celdas fuera de la diagonal muestran la relación entre pares de variables; la diagonal presenta la distribución individual de cada variable.

La matriz de dispersión confirma visualmente los hallazgos del mapa de calor: no existe relación lineal apreciable entre ningún par de variables numéricas. Las nubes de puntos en cada celda se presentan de forma rectangular y dispersa, sin ninguna tendencia diagonal que indicaría correlación. Las distribuciones en la diagonal son uniformes, coherentes con todas las observaciones previas del análisis univariado.

Más allá de confirmar la ausencia de correlación lineal, la matriz de dispersión permite inspeccionar visualmente si existen relaciones no lineales o estructuras de agrupamiento latentes entre las variables. El análisis detallado de las nubes de puntos no revela patrones de curvatura, agrupamientos por conglomerados ni estructuras en forma de “L” o “U” que pudieran sugerir relaciones no lineales de interés. La uniformidad rectangular de todas las nubes de dispersión es consistente con la generación

independiente de cada variable, lo que confirma que el dataset fue construido mediante un proceso de muestreo aleatorio independiente para cada columna numérica. Esta arquitectura de generación de datos, aunque válida para propósitos pedagógicos y de entrenamiento metodológico, excluye por construcción las correlaciones cruzadas que caracterizan a los datos reales de incidentes cibernéticos, donde variables como el tipo de ataque y el sector objetivo sí tienen una influencia documentada sobre el tiempo de resolución y el impacto financiero.

8 Análisis Temporal

8.1 Tendencia de incidentes por año (2015–2024)




Figura 13: Distribución temporal de los incidentes cibernéticos entre 2015 y 2024 (panel superior izquierdo de imagen_1). El eje X representa los años y el eje Y el número de incidentes registrados por período.

La distribución temporal muestra una frecuencia constante de aproximadamente 280–320 incidentes por año durante todo el período analizado. No se observan tendencias de crecimiento ni decrecimiento pronunciadas, lo que refleja el diseño balanceado del dataset. En el contexto real, los informes de ciberseguridad documentan un aumento sostenido de los ataques, especialmente en el período 2020–2024 como consecuencia de la aceleración digital derivada de la pandemia.

La estabilidad temporal del dataset contrasta marcadamente con la dinámica observable en los reportes anuales de ciberseguridad de organizaciones como Verizon, IBM Security y CrowdStrike, que documentan un incremento sostenido en el número y la sofisticación de los ciberataques durante el período 2015–2024. En particular, los años 2020–2022 registraron un aumento pronunciado de incidentes de ransomware y phishing asociados a la pandemia de COVID-19, el teletrabajo masivo y la digitalización acelerada de servicios esenciales. La ausencia de esta tendencia creciente en el dataset analizado limita su utilidad para el modelado de series temporales y la predicción de volúmenes futuros de incidentes; sin embargo, el período cubierto es suficientemente amplio como para servir de base para análisis transversales sobre

la tipología y el impacto de las amenazas, que constituyen el núcleo de este trabajo exploratorio.

9 Discusión

Los resultados del análisis exploratorio permiten extraer las siguientes conclusiones principales:

Sobre la estructura del dataset: el dataset es de alta calidad en términos de completitud (0 valores nulos en 3.000 registros). La distribución uniforme de las variables sugiere un origen sintético o altamente balanceado, lo que limita la extracción de patrones en las colas de las distribuciones, pero facilita el aprendizaje metodológico.

Sobre los tipos de ataque: DDoS es el vector más frecuente, aunque todos los tipos presentan frecuencias similares. En la realidad, el phishing y el ransomware han ganado protagonismo en los últimos años por su alta tasa de éxito y el impacto económico directo que generan.

Sobre el impacto financiero: la pérdida promedio de \$50.49M por incidente es un indicador significativo. La ausencia de correlación con el tiempo de resolución indica que la respuesta rápida por sí sola no garantiza una reducción de pérdidas; los controles preventivos son igualmente críticos.

Sobre las fuentes de ataque: la distribución cuasi-equitativa entre actores estatales, grupos hacktivistas, amenazas internas y fuentes desconocidas evidencia que las organizaciones deben adoptar un enfoque de defensa holístico que contemple tanto amenazas externas sofisticadas como riesgos internos.

Limitaciones: el análisis está restringido a las variables disponibles. Variables como el vector de entrada del ataque, la sofisticación del actor amenazante o el nivel de madurez de la organización atacada no están representadas, lo que limita el poder predictivo de cualquier modelo derivado de este EDA.

10 Conclusiones

El presente análisis exploratorio del dataset *Global Cybersecurity Threats 2015–2024* ha constituido un ejercicio riguroso de caracterización estadística del panorama global de amenazas cibernéticas durante una década relevante para la historia de la seguridad informática. Los hallazgos obtenidos no solo describen la estructura interna del conjunto de datos analizado, sino que ofrecen una base conceptual y metodológica para la formulación de estrategias de defensa cibernética en contextos organizacionales reales.

En primer lugar, el estudio demuestra que el dataset exhibe una calidad formal elevada: la ausencia total de valores nulos en 3.000 registros y la coherencia tipológica de las diez variables garantizan la integridad del proceso analítico. Esta completitud es una condición necesaria —aunque no suficiente— para la construcción de modelos predictivos fiables, y pone de manifiesto la importancia de los procesos de curación y

validación de datos en la cadena de valor del análisis de amenazas cibernéticas. Desde una perspectiva metodológica, el dataset constituye un instrumento pedagógico eficaz para la enseñanza de técnicas de EDA aplicadas a la ciberseguridad, si bien su naturaleza sintética impone limitaciones específicas que deben ser explícitamente reconocidas al extrapolar los resultados a entornos operativos reales.

En segundo lugar, el análisis de la distribución de tipos de ataque revela que DDoS emerge como el vector más frecuente en el dataset, si bien todos los tipos de ataque registrados —Phishing, Ransomware, SQL Injection, Man-in-the-Middle y Malware— presentan frecuencias estadísticamente comparables. Esta distribución balanceada debe interpretarse a la luz de la evidencia empírica disponible en la literatura especializada, que documenta el ascenso sostenido del ransomware y el phishing como vectores predominantes en los últimos cinco años, impulsados por la sofisticación creciente de los grupos de cibercrimen organizado y por la rentabilidad demostrada de estos modelos de ataque. La equiparabilidad frecuencial observada en el dataset debe motivar a las organizaciones a no descuidar ningún vector de ataque en su planificación de seguridad, evitando el error estratégico de concentrar recursos defensivos en un único tipo de amenaza.

En tercer lugar, el análisis sectorial evidencia una exposición transversal al riesgo cibernético que abarca desde tecnología e infraestructura crítica hasta educación y comercio minorista. Este hallazgo tiene implicaciones directas para la política de ciberseguridad: la protección del ciberespacio no puede recaer exclusivamente en los sectores tradicionalmente considerados de alto riesgo, sino que debe articularse como un esfuerzo sistémico que involucre a actores de todos los sectores económicos, incluidas las pequeñas y medianas empresas que históricamente han contado con menor capacidad de inversión en ciberseguridad. Los marcos regulatorios emergentes, como la Directiva NIS2 en Europa o los estándares NIST en Estados Unidos, apuntan precisamente en esta dirección, estableciendo requisitos de seguridad mínimos para organizaciones de todos los tamaños en sectores considerados esenciales.

En cuarto lugar, la distribución cuasi-equitativa de las fuentes de ataque entre actores estatales, fuentes desconocidas, amenazas internas y grupos hacktivistas plantea uno de los retos más complejos de la ciberseguridad contemporánea: la diversidad de perfiles de amenaza exige estrategias de defensa igualmente diversas que combinen controles técnicos avanzados —detección de intrusiones, autenticación multifactor, cifrado de extremo a extremo— con medidas organizacionales —gestión de identidades y accesos, capacitación en conciencia de seguridad, protocolos de manejo de datos sensibles— y con capacidades de inteligencia de amenazas que permitan anticipar los vectores y objetivos de los distintos tipos de actores.

En quinto lugar, el hallazgo más significativo desde el punto de vista estadístico es la práctica ausencia de correlación entre las variables numéricas del dataset (coeficientes de Pearson $\approx 0,00$). Este resultado implica que, bajo las condiciones representadas en el dataset, las métricas de impacto son estadísticamente independientes entre sí: el número de usuarios comprometidos no predice la magnitud de la pérdida financiera, y el tiempo de resolución no guarda relación con ninguna de las otras dos métricas. Esta independencia estadística, aunque contraintuitiva, sugiere que los determinantes del impacto cibernético son fundamentalmente de naturaleza cualitativa —tipo de ataque, sector objetivo, postura de seguridad preexistente,

cobertura de seguros— y no cuantitativa, lo que otorga un valor especial al enriquecimiento del dataset con variables categóricas adicionales y al uso de técnicas de análisis multivariado no lineal para capturar las interacciones reales entre estas dimensiones.

Finalmente, desde una perspectiva prospectiva, este trabajo abre múltiples líneas de investigación futura. La integración del dataset con fuentes de datos reales de incidentes cibernéticos —como los reportes anuales de Verizon DBIR, los datos de la plataforma Have I Been Pwned o las bases de datos del Centro de Coordinación CERT— podría dotar al análisis de una dimensión empírica que permita contrastar y enriquecer los patrones identificados en el dataset sintético. Asimismo, la aplicación de técnicas de aprendizaje automático supervisado —regresión para la predicción del impacto financiero, clasificación para la identificación del vector de ataque— y no supervisado —agrupamiento para la segmentación de perfiles de incidentes— sobre este dataset constituiría un paso natural hacia la construcción de herramientas de soporte a la decisión en materia de gestión del riesgo cibernético. La ciberseguridad basada en datos es hoy una imperativa organizacional, y trabajos como el presente sientan las bases metodológicas para su desarrollo sistemático.

11 Referencias

- [1] McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61.
- [2] Hunter, J.D. (2007). Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90–95.
- [3] Waskom, M. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.
- [4] Plotly Technologies Inc. (2015). *Collaborative data science*. Plotly Technologies Inc. <https://plot.ly>
- [5] ydata-profiling. (2023). *ydata-profiling: Extended Pandas Profiling*. <https://github.com/ydataai/ydata-profiling>
- [6] Dataset: *Global Cybersecurity Threats 2015–2024*. Kaggle.
- [7] Verizon. (2024). *Data Breach Investigations Report 2024*. Verizon Communications.
- [8] IBM Security. (2024). *Cost of a Data Breach Report 2024*. IBM Corporation.
- [9] World Economic Forum. (2024). *Global Cybersecurity Outlook 2024*. WEF.
- [10] NIST. (2018). *Framework for Improving Critical Infrastructure Cybersecurity, Version 1.1*. National Institute of Standards and Technology. <https://doi.org/10.6028/NIST.CSWP.04162018>
- [11] European Union Agency for Cybersecurity (ENISA). (2023). *ENISA Threat Landscape 2023*. Publications Office of the European Union.
- [12] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.